3/2/2026

الجامعة السورية الخاصة
SYRIAN PRIVATE UNIVERSITY

Report

تقديم الطلاب :

محمد عمرو زعيتر
حسن حيدر

إشراف :

د. مدين عبد الحميد
م. تقى الزعبي

مشروع فصلي

فكرة المشروع : تحليل إشارات تخطيط القلب وتصنيف اضطرابات ضربات القلب و التنبؤ بالامراض المزمنة



اولا :

1.1 التمهيد

تعد أمراض القلب والأوعية الدموية المسبب الأول للوفيات في العالم، حيث تشير إحصائيات منظمة الصحة العالمية (Who, 2025) إلى أن حوالي 19.8 مليون شخص يموتون سنوياً بسبب هذه الأمراض. من بين هذه الأمراض، تُعتبر اضطرابات ضربات القلب (arrhythmias) من أكثر الحالات شيوعاً وخطورة، حيث قد تؤدي إلى السكتة القلبية المفاجئة إذا لم يتم اكتشافها وعلاجها مبكراً.

يُعد تخطيط القلب الكهربائي (ecg) الأداة الأساسية لتشخيص اضطرابات ضربات القلب، حيث يسجل النشاط الكهربائي للقلب ويكشف عن أي خلل في نظم القلب. ومع ذلك, فإن تحليل إشارات ecg يعتمد بشكل كبير على خبرة الطبيب وقدرته على ملاحظة الأنماط الدقيقة في الإشارات، وهو أمر قد يكون صعباً ويستغرق وقتاً طويلاً، خاصة مع المرضى الذين يحتاجون مراقبة مستمرة.

في ظل هذه التحديات, برز الذكاء الاصطناعي وتعلم الآلة كأدوات واعدة لتحليل إشاراتecg بشكل آلي ودقيق. يمكن لهذه التقنيات التعرف على الأنماط المعقدة في الإشارات الكهربائية لقلب وتصنيف اضطرابات ضربات القلب بدقة قد تفوق الدقة البشرية، مما يساهم في التشخيص المبكر والتدخل السريع لإنقاذ الأرواح

2.مشكلة البحث

على الرغم من التطور الكبير في تقنيات تحليل الإشارات الطبية، لا يزال تشخيص اضطرابات ضربات القلب يواجه عدة تحديات. من الناحية الطبية، يعتمد التشخيص التقليدي على الفحص البصري لإشارات ECG من قبل أطباء القلب، وهي عملية مرهقة وعرضة للخطأ البشري، خاصة في الحالات المعقدة أو عند مراقبة المرضى لفترات طويلة.

من الناحية البحثية، أظهرت الدراسات السابقة في مجال تصنيف اضطرابات ضربات القلب

باستخدام تعلم الآلة تركيزاً على أنواع محدودة من الاضطرابات, بينما هناك حاجة لتصنيف شامل يغطي جميع أنواع الاضطرابات الرئيسية.

كما أن معظم الدراسات اعتمدت على بيانات ecg محدودة أو قديمة، مما يحد من تعميم النتائج على الحالات المختلفة.

بناءً على ما تقدم، تتمثل مشكلة البحث في الحاجة إلى تطوير نظام ذكي قادر على تحليل إشارات ECG وتصنيف اضطرابات ضربات القلب المختلفة بدقة عالية، مع التغلب على القيود الموجودة في الدراسات السابقة من حيث تنوع البيانات وشمولية التصنيف.

بناءً على ما تقدم، تتمثل مشكلة البحث في الحاجة إلى تطوير نظام ذكي قادر على تحليل إشارات ECG وتصنيف اضطرابات ضربات القلب المختلفة بدقة عالية، مع التغلب على القيود الموجودة في الدراسات السابقة من حيث تنوع البيانات وشمولية التصنيف.

ثانيا: الدراسة المرجعية

الدراسات المرجعية :

نستعرض في هذا الفصل بعض المشاريع الحديثة التي تناولت استخدام تقنيات تعلم الآلة في تحليل إشارات تخطيط القلب وتصنيف اضطرابات ضربات القلب. نسلط الضوء على النتائج التي توصلت إليها هذه المشاريع، ونقاط القوة والضعف في كل منها، مما يوفر خلفية تساعد في وضع أسس منهجية المشروع الحالي.

استخدمت الدراسة [1]

بيانات تخطيط القلب من قاعدة بيانات MIT-BIH Arrhythmia المتوفرة على منصةKaggle ، حيث هدفت إلى تصنيف نبضات القلب إلى عدة فئات اعتمادًا على إشارات .ECG تم إجراء عدة خطوات للمعالجة المسبقة شملت تنظيف البيانات وتطبيع القيم وتقسيم البيانات إلى مجموعات تدريب واختبار. تم تدريب عدة نماذج تعلم آلي مثل Random Forest و Support Vector Machineو Logistic Regression.أظهرت النتائج أن نموذج Random Forest حقق أفضل أداء بدقة بلغت حوالي 95%، مما يشير إلى قدرة النموذج على التمييز بين أنواع ضربات القلب المختلفة بكفاءة جيدة.

اقترحت الدراسة [2]

منهجية تعتمد على تحليل إشارات تخطيط القلب باستخدام تقنيات التعلم الآلي مع التركيز على معالجة مشكلة عدم توازن البيانات. استخدمت الدراسة مجموعة بيانات MIT-BIH ECG Heartbeat Dataset منKaggle ، وتم تطبيق تقنيات المعالجة المسبقة مثل تطبيع البيانات وإعادة توازن الفئات باستخدام تقنيات معالجة البيانات. تم تدريب عدة نماذج منها K-Nearest Neighbors و Decision Treeو .Random Forestأظهرت النتائج أن نموذج Random Forestقدم أفضل أداء بدقة بلغت حوالي 94% مع تحسين واضح في مقاييس التقييم مثل.F1-Score

ركزت الدراسة [3]

على تحليل بيانات تخطيط القلب باستخدام عدة خوارزميات تصنيف بهدف التنبؤ باضطرابات القلب المختلفة. استخدمت الدراسة بيانات ECG من Kaggle، وتم إجراء عمليات المعالجة المسبقة مثل Feature Scaling وتقسيم البيانات إلى بيانات تدريب واختبار. تم تدريب عدة نماذج تعلم آلي مثل Support Vector Machineو Random Forestو Logistic Regression. أظهرت النتائج أن نموذج SVM قدم أداءً جيدًا بدقة بلغت حوالي 93% في تصنيف أنواع ضربات القلب المختلفة.

تناولت الدراسة [4]

مشكلة تصنيف نبضات القلب غير الطبيعية باستخدام إشاراتECG ، حيث اعتمدت على بيانات MIT-BIH Arrhythmia المتوفرة على Kaggle. تضمنت خطوات المعالجة المسبقة تنظيف البيانات وإزالة القيم الشاذة بالإضافة إلى تطبيع الإشارات. تم تدريب نماذج تعلم آلي مثل Random Forest و-K Nearest Neighborsلتصنيف ضربات القلب. أظهرت النتائج أن نموذج Random Forestحقق أفضل أداء بدقة وصلت إلى حوالي 96%، مما يدل على فعاليته في تحليل البيانات الطبية واكتشاف الأنماط المختلفة في إشارات القلب.

هدفت الدراسة [5]

إلى تحليل وتصنيف إشارات تخطيط القلب باستخدام مجموعة من تقنيات تعلم الآلة. اعتمدت الدراسة على بيانات ECG من Kaggle وتم إجراء عمليات المعالجة المسبقة مثل تطبيع البيانات واستخراج بعض الخصائص المهمة من الإشارة. تم تدريب عدة نماذج مثل Support Vector Machine و Decision Tree و Random Forest. أظهرت النتائج أن نموذج Random Forest حقق أفضل أداء بدقة تقارب 94%، كما تم استخدام منحنيات ROC لتقييم أداء النماذج المختلفة.

ركزت الدراسة [6]

استخدام تقنيات تعلم الآلة لتصنيف اضطرابات القلب اعتمادًا على بيانات تخطيط القلب ECG. استخدمت الدراسة مجموعة بيانات MIT-BIH المتوفرة على Kaggle، وتم تنفيذ عدة خطوات للمعالجة المسبقة مثل تنظيف البيانات وتطبيع الإشارة وتقسيم البيانات إلى بيانات تدريب واختبار. تم تدريب نماذج مثل Logistic Regression وK-Nearest Neighbors وRandom Forest. أظهرت النتائج أن أفضل نموذج حقق دقة وصلت إلى حوالي 95%، مما يوضح إمكانية استخدام تقنيات التعلم الآلي في دعم تشخيص أمراض القلب.

رقم الدراسة	الباحث	الخوارزميات المستخدمة	اعلى دقة محققة	مقاييس التقييم	الايجابيات	السلبيات
1	(2023)	MIT-BIH Arrhythmia Dataset (Kaggle)، تم تنظيف البيانات وتطبيعها وتقسيمها إلى تدريب واختبار باستخدام LR، SVM، Random Forest	95% (Random Forest)	Accuracy ، Precision ، Recall ،F1-Score ،	مقارنة بين عدة خوارزميات تعلم آلي وتطبيق معالجة مسبقة واضحة للبيانات	لم يتم معالجة مشكلة عدم توازن البيانات
2	(2024)	MIT-BIH ECG Heartbeat Dataset (Kaggle)، استخدام KNN وDecision Tree و Random Forest مع تقنيات إعادة التوازن	94% (Random Forest)	Accuracy ،F1-Score ،	معالجة مشكلة عدم توازن الفئات وتحسين أداء النماذج	التركيز على نماذج تقليدية فقط دون نماذج عميقة
3	(2023)	ECG Dataset من Kaggle، تطبيق Feature Scaling واستخدام LR وSVM وRandom Forest	(SVM) %93	Accuracy	استخدام عدة خوارزميات للمقارنة وتحسين البيانات قبل التدريب	لم يتم توضيح تفاصيل كاملة حول معالجة عدم التوازن
4	(2024)	MIT-BIH Arrhythmia Dataset (Kaggle)، استخدام KNN وRandom Forest بعد تنظيف البيانات وإزالة القيم الشاذة وتطبيع الإشارة	96% (Random Forest)	Accuracy	تحقيق دقة عالية مع معالجة مسبقة فعالة للبيانات	نقص تفاصيل بعض خطوات المعالجة أو ضبط المعاملات
5	(2023)	ECG Dataset من Kaggle، استخدام SVM و Decision Tree وRandom Forest بعد استخراج الخصائص	94% (Random Forest)	Accuracy ، ROC Curve	استخدام استخراج الخصائص وتقييم النماذج ROC باستخدام	محدودية تنوع الخوارزميات المستخدمة
6	(2024)	MIT-BIH Dataset (Kaggle)، استخدام Logistic Regression وKNN وRandom Forest بعد تنظيف البيانات وتطبيعها	أفضل) 95% نموذج)	Accuracy	توضيح خطوات المعالجة المسبقة وتقسيم البيانات بشكل منهجي	الاعتماد على نماذج تقليدية فقط دون تقنيات تعلم عميق

سادساً: المصادر

[1] Rhythm of the Heart – ECG Arrhythmia Detection, Kaggle.

[2] ECG Heartbeat Classification, Kaggle.

[3] ECG Heartbeat Classification Project, Kaggle.

[4] Heartbeat Classification using Machine Learning, Kaggle.

[5] ECG Classification Project, Kaggle.

[6] ECG Arrhythmia Classification, Kaggle.

أهداف المشروع 1.3

الهدف العام :

وتصنيف (ECG) يهدف هذا المشروع إلى بناء نظام لتحليل إشارات تخطيط القلب
اضطرابات ضربات القلب و الكشف المبكر للامراض

الأهداف الفرعية:

1. . جمع وتحليل بيانات إشارات ECG من مصادر موثوقة

MIT-BIH Arrhythmia Database

2. تطبيق تقنيات معالجة الإشارات processing signal

لاستخراج الميزات من إشارات.ECG

4. مقارنة أداء الخوارزميات باستخدام مقاييس التقييم المناسبة

(الدقةPrecision ،Recall ،F1-Score).